

WYDZIAŁ PODSTAWOWYCH PROBLEMÓW TECHNIKI
POLITECHNIKA WROCŁAWSKA

SYSTEMY REKOMENDACJI
OPARTE NA
BŁĄDZENIU LOSOWYM

PIOTR KASPROWICZ
NR INDEKSU: 236609

Praca inżynierska napisana
pod kierunkiem
dra inż. Jakuba Lemiesza



Politechnika
Wrocławska
WROCŁAW 2019

Spis treści

1	Wstęp	1
2	Systemy rekomendacji	3
2.1	Rodzaje systemów rekomendacji	3
2.2	Pobieranie informacji	4
2.3	Content-based filtering	6
2.4	Collaborative filtering	8
2.5	Spacery losowe	10
2.6	Globalne systemy rankingowe	11
2.7	Spacery losowe z restartami	12
2.8	Absorbujące spacery losowe	13
3	Implementacja systemu	15
3.1	Opis zadania	15
3.2	Technologie	15
3.3	Baza danych	15
3.4	Mechanizm działania systemu rekomendacji	16
4	Testy algorytmów	19
4.1	Przykład użycia	19
4.2	Lista recenzentów	20
4.3	Współczynnik tłumienia	22
5	Instalacja i wdrożenie	23
6	Podsumowanie	25
	Bibliografia	27
A	Zawartość płyty CD	29

Wstęp

We współczesnym nam świecie istnieje ciągle potrzeba tworzenia ofert i polecania produktów różnym klientom. Proste mechanizmy takie jak lista bestsellerów w księgarni internetowej, czy lista nowych produktów w sklepie z odzieżą stają się niewystarczające. Celem zwiększenia swoich szans w walce z konkurencją oraz zmaksymalizowania dochodów serwisy internetowe zaczęły rozglądać się za sposobem na ustalenie gustu indywidualnego klienta.

Z pomocą przyszły systemy rekomendacji, które pozwalają na stworzenie oferty spersonalizowanej pod wybranego użytkownika. Sprawdziły się one w swoim zadaniu tak efektywnie, że korzysta z nich większość serwisów internetowych. W branży e-handlu (ang. *e-commerce*) Amazon stał się liderem sprzedaży stosując takie systemy przy polecaniu aukcji, serwisy hostujące wideo oraz muzykę np. Youtube czy Spotify nie byłyby tak efektywne w proponowaniu kolejnych filmów czy utworów, a wyszukiwanie znajomych na portalu społecznościowym takim jak Facebook, który w sierpniu 2019 roku przekroczył 2.45 milarda aktywnych użytkowników [5] byłoby po prostu niemożliwe.

Główną ideą stojącą za silnikami rekomendacji jest znalezienie pewnego podobieństwa między użytkownikiem, a produktami lub innymi użytkownikami, a następnie stworzenie rankingu, który je porówna. Biorąc pod uwagę jak szeroko są one wykorzystywane doczekały się wielu różnych podejść implementacji. Dwa główne, które możemy wyróżnić to metoda Content-based filtering, która polega na polecaniu produktów na podstawie tego czym użytkownik interesował się w przeszłości oraz metoda Collaborative filtering, w której przy rekomendacji wykorzystujemy informacje jakie produkty podobały się użytkownikom o podobym guście [11]. Wszelkie inne stanowią kombinacje obu technik z zamiarem dopasowania systemu do konkretnego problemu lub rozwiązania problemu dotyczącego, którąś z powyższych koncepcji.

Celem pracy jest porównanie metod stosowanych w procesie tworzenia systemu rekomendacji, a następnie stworzenie takiego systemu w oparciu o błędzenie losowe w kontekście problemu przydzielania recenzentów do oceniania prac naukowych.

Praca składa się z czterech rozdziałów. W rozdziale pierwszym znajduje się opis oraz klasyfikacja systemów rekomendacji oraz opis spacerów losowych i tego w jaki sposób wykorzystuje się przy tworzeniu takich programów.

W rozdziale drugim przedstawiono opis stworzonego systemu.

W rozdziale trzecim znajduje się testy zaimplementowanej części.

W rozdziale czwartym przedstawiono sposób instalacji i wdrożenia systemu w środowisku docelowym.

Końcowy rozdział stanowi podsumowanie uzyskanych wyników.



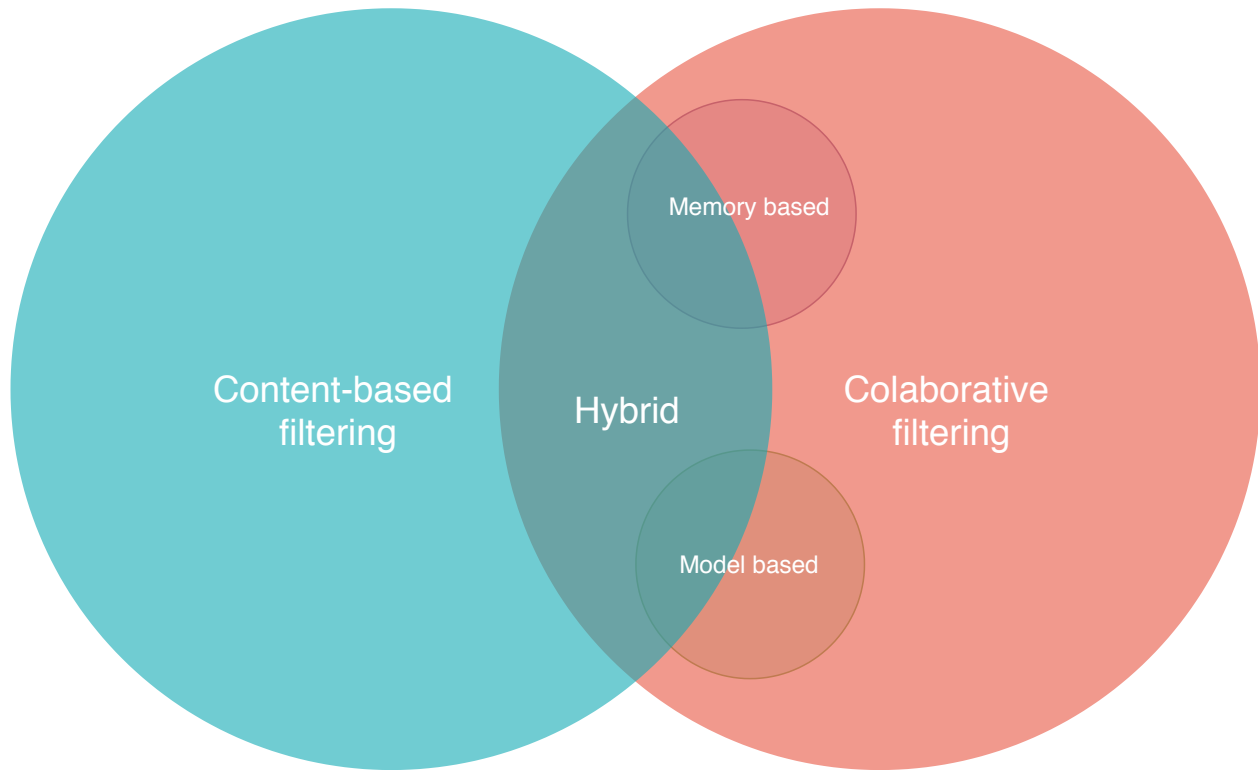
Systemy rekomendacji

2.1 Rodzaje systemów rekomendacji

Systemy rekomendacji to rodzaj filtrów informacji, które powstały w celu odnalezienia w zbiorze danych produktu, który trafi w osobiste preferencje użytkownika. Występują one w całym Internecie rozpowszechnione za sprawą wyszukiwarek internetowych, dla których początkowo powstały. Jednym z pierwszych takich miejsc, w którym możemy się na nie natknąć pojawia się przy okazji autouzupełniania (ang. *autocomplete*) wpisywanego tekstu. Naturalne stało się to, że nowoczesne narzędzia tworzą dla nas podpowiedzi, co dzieje się na podstawie częstotliwości wpisanych fraz przez innych użytkowników oraz historii naszych wcześniejszych wyszukiwań. W ten sposób pomagają one uniknąć takich pomyłek jak błędy ortograficzne czy literówki. Dodatkowo, zastosowanie takiego mechanizmu w wyszukiwarce internetowej ułatwia jej udzielenie poprawnej odpowiedzi na stworzone zapytanie, poprzez zaproponowanie specjalistycznego słownictwa lub synonimu, który lepiej pasuje w danym kontekście. Przechodząc do wyszukiwarek natrafiamy na kolejny przykład wykorzystania naszych systemów, a mianowicie globalne systemy rankingowe, czyli sposób na ocenę i pozycjonowanie wszystkich stron internetowych w wynikach wyszukiwania. Dokładna zasada działania algorytmu PageRank stojąca za najczęściej wykorzystywaną przeglądarką Google została opisana w dalszej części pracy w rozdziale poświęconemu temu zagadnieniu.

Jednakże zastosowaniem, na którym skupia się ta praca jest personalizacja wyników pod konkretnych użytkowników w skrócie PRES (akronimu ang. *Personalized Recommender System*). Takie silniki rekomendacji znajdują swoje zastosowanie głównie w komercyjnych rozwiązaniach, gdzie odpowiednia propozycja może w znaczący sposób zachęcić użytkownika do ponownego skorzystania z serwisu. Najpopularniejsze aplikacje tych systemów to generowanie playlist dla serwisów wideo oraz muzyki jak Youtube i Netflix, tworzenie preferencyjnych ofert dla użytkowników aukcji internetowych takich jak Amazon czy Allegro lub tworzenie dla portali społecznościowych jak Facebook czy Twitter powiązań między użytkownikami. Ze względu na różnice w implementacji możemy rozpatrzeć 3 różne podejścia:

- metoda content-based,
- metoda collaborative filtering,
- metoda hybrydowa, która łączy dwie pierwsze podejścia.



Rysunek 2.1: Podział systemów rekomendacji

2.2 Pobieranie informacji

Zanim przejdziemy do opisu metod tworzenia rankingu, musimy w jakiś sposób zebrać dane o użytkowniku, aby poznać jego preferencje. W tym celu zasadniczo korzysta się dwóch źródeł informacji, z jawnej(ang. explicit feedback) lub domniemanej (ang. implicit feedback) informacji zwrotnej. Pierwszą uzyskujemy poprzez przeprowadzenie ankiety na nowo stworzonym koncie w celu bezpośredniego uzupełnienia informacji o interesujących nas cechach na podstawie odpowiedzi jakie zostały udzielone. Tak uzyskane informacje mogą pozytywnie wpłynąć na modelowanie użytkownika oraz generowanie rekomendacji:

- Po pierwsze pomagają pomóc w rozwiązaniu problemu dużej rzadkości danych (ang. *large data sparsity*) poprzez wymuszenie dodatkowych informacji o preferencjach użytkownika, a co za tym idzie zwiększenie relacji między obiektami w systemie.
- Po drugie rozwiązuje cold-start problem, na który napotykamy w systemach rekomendacji w momencie, gdy rejestruje się nowy użytkownik i nie mamy o nim żadnych informacji. W tym problemie rozróżniamy dwa rodzaje użytkowników: pierwszy, który miał małą styczność z obiektami w systemie oraz drugi, który jest całkowicie nowy dla systemu. Dla pierwszego typu ankietę może zostać wykorzystana do wzmocnienia

oceny atrybutów w profilu użytkownika, a dla drugiego do stworzenia takiego profilu oraz polepszenia jakości całego rankingu.

- Trzecią korzyścią płynącą z zastosowania ankietyzacja użytkowników dla modeli, które nie mierzą się z problemem dużej rzadkości danych jest ustalenie jakości stworzonego rankingu poprzez porównanie go z odpowiedziami udzielonymi w ankiecie oraz rozpoznawanie ukrytych preferencji użytkownika, które nie zostały wykryte innymi metodami. [3]

Portale na których możemy się na nią natknąć np. Twitter oraz Pinterest czerpią ogromne korzyści z możliwości wyświetlania zawartości dostosowanych do użytkownika. Zaraz po rejestracji użytkownik proszony jest o ocenę jakie zawartości go interesują w celu zapewnienia spersonalizowanych rekomendacji. W ten sposób, o ile ankietowany nie skłamał w odpowiedziach możemy zaprezentować mu treści pasujące do jego upodobań.

Drugim rozwiązaniem jest wykorzystanie wcześniejszych zachowań użytkowników, może to być po prostu inny wcześniej wybrany przez niego przedmiot lub czas jaki spędzi podczas przeglądania oferty. Zbieraniem informacji o jego działaniach zajmuje się system, który monitoruje każdy jego ruch. Implementacja tego podejścia jest o wiele bardziej skomplikowana, dlatego często łączona jest z pierwszą, na przykład w serwisie YouTube przy rekomendacji filmów wykorzystywana jest informacja jawna o tym które kanały zostały przez użytkownika zasubskrybowane i polubione, oraz dodatkowo zbierane są informacje o tym, które filmy zostały przez niego obejrzone w całości, a z oglądania których zrezygnował po kilku minutach.

Jednym z najpopularniejszych algorytmem wykorzystywanym do wydobycia w taki bierny sposób ważnych z punktu widzenia systemu rekomendacji informacji jest algorytm *tf-idf*. Wykorzystywany jest on do analizy dokumentów tekstowych, w tym plików HTML. Pierwszym krokiem algorytmu jest pozbycie się z analizy tagów oraz słów, które nie zapewniają istotnych informacji np. znaki interpunkcyjne. W drugiej kolejności z pozostałej puli słów usuwane są prefisy i sufisy w celu pogrupowania wyrazów. Następnie bazując na tym jak użytkownik ocenił treść (jawny lub bierny sposób uzyskiwania informacji o preferencjach użytkownika) wybieramy te terminy, które są z punktu widzenia użytkownika interesujące w celu obliczenia wartości tych terminów przy wykorzystaniu wzoru na wartość *tf-idf*:

$$(tf-idf)_{i,j} = tf_{i,j} \times idf_i, \quad (2.1)$$

gdzie:

- $tf_{i,j}$ to tzw. „term frequency”, wyrażana wzorem:

$$tf_{i,j} = \frac{n_{i,j}}{\sum_k n_{k,j}},$$

gdzie:

- $n_{i,j}$ jest liczbą wystąpień terminu (t_i) w dokumencie d_j , a mianownik jest sumą liczby wystąpień wszystkich terminów w dokumencie d_j .
- idf_i to „inverse document frequency” wyrażana wzorem:



$$\text{idf}_i = \log \frac{|D|}{|\{d : t_i \in d\}|},$$

gdzie:

- $|D|$ – liczba dokumentów w korpusie,
- $|\{d : t_i \in d\}|$ – liczba dokumentów zawierających przynajmniej jedno wystąpienie danego terminu.

2.3 Content-based filtering

Metoda Content-based (CB) filtering przedstawia podejście, które rekomenduje użytkownikowi produkty na podstawie utworzonych wcześniej profili użytkownika. Ten sposób najlepiej sprawdza się w sytuacji, gdy znamy dokładne informacje o produkcie (nazwa, lokalizacja, opis), ale nie o użytkowniku.

Na początku zarówno dla przedmiotów jak i użytkowników tworzymy profil zapamiętany przy pomocy wektora $X = (x_1, x_2, \dots, x_n)$, gdzie x_n reprezentuje pewną interesującą nas cechę lub atrybut. Następnie porównując wybrane wektory jesteśmy w stanie przy pomocy różnych metryk obliczyć odległości między nimi i stworzyć ranking, który pozwoli na wybranie tych przedmiotów, które najbardziej pokrywają się z wektorem użytkownika. W rezultacie otrzymujemy listę przedmiotów, które pokrywają się z upodobaniami użytkownika.

Pierwszą z takich miar używanych w przypadku, kiedy nasze wektory są binarne (wektorze składa się z samych zer i jedynek) jest odległość Hamminga. Jej wartość dla dwóch ciągów tej samej długości to liczba pozycji (miejs), na które dane ciągi mają różne wartości. Niestety możemy zastosować ją jedynie, jeśli możemy nasze atrybuty reprezentować zero-jedynkowo. W przypadku, gdy wartości w wektorach to liczby rzeczywiste możemy zastosować na przykład prostą odległość euklidesową, która odpowiada długości odcinka między dwoma punktami o współrzędnych określonych przez wektor [13].

Wartość tej metryki definiujemy następująco, jeśli w kartezjańskim układzie współrzędnych, $\mathbf{a} = (a_1, a_2, \dots, a_n)$ i $\mathbf{b} = (b_1, b_2, \dots, b_n)$ są dwoma punktami w n -wymiarowej przestrzeni Euklidesowej to odległość (d) między \mathbf{a} i \mathbf{b} lub \mathbf{b} i \mathbf{a} wynosi:

$$\begin{aligned} d(\mathbf{a}, \mathbf{b}) &= d(\mathbf{a}, \mathbf{b}) = \sqrt{(a_1 - b_1)^2 + (a_2 - b_2)^2 + \dots + (a_n - b_n)^2} \\ &= \sqrt{\sum_{i=1}^n (a_i - b_i)^2}. \end{aligned} \quad (2.2)$$

W przypadku porównania przedmiotów (ang. *item-to-item*) najczęściej wykorzystywana jest jedna z dwóch następujących metryk:

- Odległość kosinusowa to kosinus kąta między dwoma wektorami reprezentującymi dwóch użytkowników lub dwa produkt - znormalizowany iloczyn skalarny wektorów [10]. Jego

wartość $\cos(\theta)$ obliczana jest następująco:

$$\cos(\theta) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|} = \frac{\sum_{i=1}^n a_i b_i}{\sqrt{\sum_{i=1}^n a_i^2} \sqrt{\sum_{i=1}^n b_i^2}} \quad (2.3)$$

Wykorzystywana jest ona między innymi w sklepie internetowym Amazon [8].

- Indeks Jaccarda zdefiniowana jako część wspólna zbiorów A i B przez ich sumę mierzy podobieństwo pomiędzy dwoma zbiorami:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}. \quad (2.4)$$

Podobnie jak odległość Hamminga współczynnik podobieństwa Jaccarda znajduje swoje zastosowanie w systemach rekomendacji, tylko w sytuacji, gdy wektory reprezentowane są poprzez wartości binarne.

Dzięki zastosowaniu jednej z takich metryk jesteśmy w stanie ustalić odległość między wektorami w przestrzeni liniowej. Jednakże dane te nie muszą być gotowe do porównania i analizy. Rozważmy system rekomendacji, który ocenia filmy i dwoma użytkownikami, których będziemy chcieli porównywać będą krytykami filmowy. Jeśli jeden z nich konsekwentnie ocenia wyżej niż drugi, wtedy odległość będzie duża, a przewidywane prawdopodobieństwo małe. Z tego powodu musimy zastosować normalizację ocen, aby każdy z nich znalazł się w postaci standardowej. [13]

Dla N -wymiarowego wektora $x_u = (x_{u1}, x_{u2}, \dots, x_{uN})$, opisującego użytkownika u , gdzie x_{un} jest oceną produktu n . Obliczamy średnią dla próby \bar{x}_u oraz odchylenie standardowe próbki s_u w następujący sposób:

$$\bar{x}_u = \frac{1}{N} \sum_{n=1}^N x_{un} \quad (2.5)$$

$$s_u = \sqrt{\frac{1}{N-1} \sum_{n=1}^N (x_{un} - \bar{x}_u)^2} \quad (2.6)$$

Następnie zmieniamy zmienną niestandardyzowaną x_{un} na postać standaryzacji Z :

$$z_{un} = \frac{x_{un} - \bar{x}_u}{s_u} \quad (2.7)$$

Na koniec silnik rekomendacji po obliczeniu miary podobieństwa pomiędzy przedmiotami a użytkownikami tworzy listę najlepszych rekomendacji. Jeśli nieporządkowane jest, aby użytkownikowi został polecany produkt, który jest znany użytkownikowi systemu usuwa te pozycje, a następnie prezentuje wynik użytkownikowi. Wadą Content-based filtering jest potrzeba wydobycia charakterystycznych cech z przedmiotu, co nie zawsze jest wykonalne. Jeśli przedmiot posiada opis tekstowy, z którego możemy przy pomocy na przykład algorytmu tf-idf uzyskać o nim informacje, wtedy metoda content-based zadziała bez zażutku. Jednakże problem napotykamy w momencie, gdy chcemy dokonać oceny muzyki lub obrazu, gdyż nie istnieje wygodny sposób na stworzenie matematycznej reprezentacji (profilu) takich obiektów.



2.4 Collaborative filtering

Druga z metod stosowanych w systemach rekomendacji to collaborative filtering (CF), która bazuje na pomysłu, że użytkownikom o podobnych upodobaniach odpowiadają podobne produkty. W tym przypadku nie wykorzystujemy charakterystyki produktów, upodobania użytkownika są tworzone na podstawie jego historii z produktami np. jakie produkty kupił, a następnie na tej podstawie obliczane są korelacje między użytkownikami. Dopiero te korelacje służą do stworzenia dopasowania produktów dla konkretnego użytkownika.

W algorytmach rekomendacji wykorzystujących collaborative filtering wyróżniamy 2 grupy:

- metody wykorzystujące pamięć,
- metody wykorzystujące model.

W metodach wykorzystujących pamięć ponownie można wydzielić 2 typy ze względu na to jakie dane przetwarzają: filtracja użytkownik-produkt (ang. *user-item filtering*) oraz filtracja produkt-produkt (ang. *item-item filtering*). Przykładem aplikacji filtracji użytkownik-produkt jest algorytm klasyfikacji K najbliższych sąsiadów, który znajduje grupy użytkowników o podobnych zainteresowaniach. Przepływ pracy w tym przypadku standardowo przebiega w 3 krokach:

- Użytkownik ocenia dany produkt. Może to się dokonać tak samo jak w poprzedniej metodzie w sposób jawny (ang. *explicit feedback*) lub bierny (ang. *implicit feedback*). Pierwszy polega na bezpośredniej ocenie produktu przez użytkownika, a drugi na analizie jego zachowań.
- System porównuje ocenę produktów użytkownika z oceną innych użytkowników i na tej podstawie wyszukuje tych, którzy mają podobne upodobania jak ten dla którego tworzymy rekomendacje.
- Na końcu system rekomenduje przedmioty, które użytkownicy o podobnym guście ocenili wysoko, lecz nie zostały one jeszcze ocenione przez tego użytkownika.

Z kolei w przypadku filtracji produkt-produkt cały proces przebiega w następujący sposób:

- Ocena produktów przez użytkownika przebiega identycznie jak w filtracji użytkownik-produkt,
- Utworzona zostaje macierz reprezentująca relacje między każdą parą przedmiotów.
- Na końcu system na wyszukuje w macierzy te przedmioty, które podobały się użytkownikowi, na tej podstawie odszukuje tych użytkowników, których lubili te przedmioty i zwraca inne produkty, które lubili.

Podsumowując w pierwszym przypadku dane wejściowe to użytkownicy, a dane wyjściowe to produkty, a w drugim zarówno dane wejściowe jak i wyjściowe stanowią produkty. W skrócie filtracja użytkownik-produkt może zostać opisana jako “Użytkownicy podobnym do

ciebie również podobało się...”, a filtracja produkt-produkt “Użytkownicy, którzy polubili ten produkt również polubili...”.

Podobnie jak przy metodzie content-based, podobieństwo obliczane jest za pomocą metryk. Do tego celu wykorzystywana jest opisana już wcześniej odległość kosinusowa lub bardziej popularny w przypadku collaborative filtering współczynnik korelacji Pearsona. Do oszacowania korelacji między ocenami po pierwsze normalizujemy je przy wykorzystaniu wzorów (2.5), (2.6) i (2.7) do postaci standardowej, następnie obliczamy korelację między użytkownikami x i y według następującego wzoru:

$$\begin{aligned} r_{xy} &= \frac{1}{N-1} \sum_{n=1}^N \left(\frac{x_n - \bar{x}}{s_x} \right) \left(\frac{y_n - \bar{y}}{s_y} \right) \\ &= \frac{1}{N-1} \sum_{i=n}^N z_{xn} z_{yn} \end{aligned} \quad (2.8)$$

gdzie:

- N - wymiar wektora x oraz y ,
- $x_u = (x_{u1}, x_{u2}, \dots, x_{uN})$, opisuje użytkownika u , gdzie x_{un} jest oceną produktu n , analogicznie dla y ,
- \bar{x}, \bar{y} - średnia dla próby
- s_x, s_y - odchylenie standardowe

Korelacja prezentuje wynik w następujący sposób: jeśli z_{xn} jest duże, gdy z_{yn} jest duże oraz, gdy z_{xn} jest małe, gdy z_{yn} jest małe wynik korelacji będzie zmierzał do 1. Jeśli z_{xn} jest duże, gdy z_{yn} jest małe oraz, gdy z_{xn} jest małe, gdy z_{yn} jest duże wynik korelacji będzie zmierzał do -1 . W przypadku braku korelacji między użytkownikami wynik korelacji będzie zmierzał do 0 [13].

Druga metoda (ang. *model-based collaborative filtering*) polega na stworzeniu rankingu wykorzystując model. W tym przypadku spotyka się takie techniki jak: naiwny klasyfikator bayesowski, który jest wykorzystywany przy uczeniu z nadzorem (ang. *supervised learning*), analiza skupień (ang. *clustering models*), przetwarzanie języka naturalnego (ang. *latent semantic analysis*) czy też procesy decyzyjne Markowa.


Przy wykorzystaniu podejścia collaborative filtering napotykamy na kilka problemów, które musimy uwzględnić podczas implementacji. Pierwsze z nich to rzadkość danych i skalowalność, które wynikają z tego, że większość komercyjnych systemów rekomendacji jest oparta na wielkich bazach danych. Przez to macierz opisująca relacje między użytkownikiem a produktami używana w metodzie CF i operacje na nich i czas obliczeń dla takiego serwisu rośnie do gigantycznych rozmiarów. Na przykład dla serwisu Twitter w tym celu stosowane są techniki redukcji nieistotnych połączeń oraz dzielenie użytkowników na wiele grup dzięki czemu możliwe jest zastosowanie architektury, która umożliwia wykonanie potrzebnych obliczeń na klastrze komputerowych (ang. *cluster*) w kilka miesięcy [6].

Kolejny problem związany z rzadkością danych jest zimny start (ang. *cold start*). Napotykamy na niego w momencie pojawienia się w systemie nowego użytkownika lub produktu.



Taki użytkownik, który nie ocenił produktów lub nowy produkt który nie został jeszcze oceniony wystarczającą ilością razy nie może być odpowiednio wdrożony do systemu. Taki obiekt nazywa jest „czarną owcą”, gdy niemożliwe jest dopasowanie rekomendacji lub „szarą owcą”, gdy rekomendacje dla danej obiektu nie są konsekwentne. Ponieważ ten problem nie pojawia się w podejściu Content-based, gdyż tam wektor cech musi zostać uzupełniony często łączy się obie metody w celu ominięcia tego problemu. Takie hybrydowe podejście nosi miano Content-Boosted Collaborative Filtering.

Ostatnim wyzwaniem jest problem długiego ogona (ang. *long tail*). W tym przypadku większość użytkowników otrzymuje jako rekomendacje, tylko nieznaczna ilość przedmiotów w systemie.



Rysunek 2.2: Zobrazowanie problemu długiego ogona, korzystając z [14]. Po prawej (żółty kolor) znajduje się długi ogon, po lewej (zielony kolor) reprezentuje małą grupę produktów, które dominują w rekomendacji.

2.5 Spacery losowe

System rekomendacji stworzy w pracy wykorzysta spacery losowe, z tego powodu zdefiniujemy spacery losowe zaczynając od pojęcia procesu stochastycznego i łańcucha Markowa. Taki proces definiujemy jako $\mathbf{X} = \{X(t) : t \in T\}$, co oznacza, że taki proces jest rodziną zmiennych losowych. Oznaczenie $X(t)$ lub X_t rozumiemy jako stan procesu w pewnym czasie t . W naszym przypadku proces jest skończony, ponieważ X_t przyjmuje wartości tylko ze zbioru skończonego. Następnie możemy zdefiniować łańcuch Markowa:

Definicja 2.1 *Proces stochastyczny z czasem dyskretnym X_0, X_1, X_2, \dots jest łańcuchem Markowa, jeśli*

$$Pr(X_1 = a_t | X_{t-1} = a_{t-1}, X_{t-2} = a_{t-2}, \dots, X_0 = a_0) = Pr(X_t = a_t | X_{t-1} = a_{t-1}) = P_{a_{t-1}, a_t}. \quad (2.9)$$

Z powyższej definicji wynika fakt nazywany własnością Markowa lub własnością braku pamięci, który mówi o tym stan X_t zależy wyłącznie od poprzedniego stanu, a nie w jaki sposób w naszym procesie dotarliśmy do stanu X_{t-1} . Jednakże należy pamiętać, że nie oznacza to, że w procesie o własności Markowa X_t jest niezależny od zmiennych losowych

$X_0, X_1, X_2, \dots, X_{t-2}$. Z tego wynika że wszystkie informacje i zależności od poprzednich stanach X_t są zawarte w wartości poprzedniego stanu X_{t-1} [9].

Spacer losowy lub inaczej błądzenie losowe to rodzaj bardzo prostego procesu stochastycznego. Może on odbywać się np. na płaszczyźnie, na prostej, w przestrzeni lub na grafach. W tej pracy spacery odbywają się na grafach, które zgodnie z definicją z [9]:

Definicja 2.2 *Spacer losowy na grafie G jest łańcuchem Markowa zdefiniowanym przez ciąg ruchów cząsteczki między wierzchołkami grafu G . W tym procesie stanem systemu jest położenie cząsteczki w danym kroku czasu. Jeśli cząsteczka jest w wierzchołku i oraz, jeśli ma $d(i)$ wychodzących krawędzi, to prawdopodobieństwo, że cząsteczka będzie poruszać wzdłuż krawędzi (i, j) i przejdzie do sąsiedniego wierzchołka j , jest równe $1/d(i)$.*

Wykorzystanie błądzenia losowe w systemach rekomendacji to wygodny sposób na przedstawienie relacji lub innych istotnych szczegółów dotyczących pewnego problemu w celu stworzenie rekomendacji. Są one w dużej mierze odporne na takie problemy jak rzadkość danych i dobrze sprawdzają się przy dużych zbiorach danych. Ze względu na różne zastosowanie możemy podzielić je na [11] :

- globalne systemy rankingowe,
- spacery losowe z restartami,
- absorbujące spacery losowe.

2.6 Globalne systemy rankingowe

Globalne systemy rankingowe prezentują wykorzystanie błądzenia losowego do stworzenia jednego globalnego rankingu dla całego systemu. Nie zapewniają one możliwości spersonalizowanych danych dla konkretnego użytkownika, jednakże stanowią trzon wyszukiwarek internetowych. Algorytm PageRank, czyli najbardziej znany przykład użycia takiego systemu jest wykorzystywany w wyszukiwarce Google.

W tym modelu każdy węzeł grafu reprezentuje jakąś stronę internetową, a skierowane krawędzie linki między nimi. Jeśli naszą sieć internetową zdefiniujemy jako graf $G = (V, E)$, gdzie V - strony internetowe, E - linki między stronami, link ze strony $u \in V$ na stronę $v \in V$ oznacza, że strona v jest ważna dla strony u . Waga strony v jest wprost proporcjonalna do wagi strony u i odwrotnie proporcjonalna do ilości linków wychodzących ze strony u . Algorytm opiera się na stworzeniu nieskończonego spaceru losowego symulując go wieloma skończonymi długimi spacerami. Zasadę działania możemy sobie wyobrazić przy pomocy randomowego surfera, który startuje z losowo wybranej strony, a następnie podąża za linkami wychodzącymi z niej. W taki sposób można stworzyć ranking stron na podstawie tego jak często daną stronę odwiedzamy. Zgodnie z definicją spaceru losowego 2.2 prawdopodobieństwo, że przejdziemy ze strony na sąsiednią stronę j wynosi $1/d(i)$, gdzie $d(i)$ to stopień tego wierzchołka.

Ze względu na rozważany przez nas model łańcucha Markowa z rozkładem stacjonarnym, musimy zapewnić nieredukowalność grafu, co w przypadku grafu sieci Internetu nie ma miejsca, gdyż nie jest on spójny. Możemy sobie z tym w łatwy sposób poradzić dodając małe



prawdopodobieństwo przejścia od wszystkich węzłów do wszystkich innych węzłów. Takie rozwiązanie zapewnia stworzenie silnie spójnego grafu. Wzorcową, nieoficjalną wersję wyniku algorytmu PageRank dla pewnej strony n prezentuje się w następujący sposób [11]:

$$PR(n) = \frac{(1 - \alpha)}{N} + \alpha \sum_{q: (q, n) \in E} \frac{PR(q)}{deg(q)} \quad (2.10)$$

gdzie:

- N - liczba stron internetowych,
- n - strona dla, której liczymy wynik,
- q - sąsiad strony n ,
- α - współczynnik tłumienia, przyjmowana wartość do obliczeń to 0.85 [11].

Czynnik $\frac{1-\alpha}{N}$ mówi o możliwości losowego skoku z dowolnego miejsca z grafu do wierzchołka aktualnego wierzchołka n , która przy zapewnianiu spójności grafu. Jednakże, ponieważ taki globalny ranking tworzy identyczną ocenę systemu niezależnie od wierzchołka w jakim zaczniemy nasz spacer, aby spersonalizować rekomendacje pod konkretny element musimy skorzystać z innego rozwiązania. Takimi rozwiązaniami są kolejno spacery losowe z restartami oraz absorbujące spacery losowe.

2.7 Spacery losowe z restartami

W PageRanku niezależnie od tego w jakim wierzchołku rozpoczniemy spacer zapewni nam taki sam wynik, ze względu na to, że bazuje on na macierzy przejść i w żaden sposób jej nie modyfikuje. Z pomocą przychodzą spacery losowe z restartami, które są rozszerzeniem takich spacerów biorące pod uwagę osobiste preferencje użytkownika. Uzyskujemy to poprzez dodanie stałej szansy na powrót do startowego wierzchołka w każdym wykonywanym kroku. Dzięki temu, wierzchołki, które znajdują się bliżej startowego punktu są oceniane wyżej od tych znajdujących się dalej. W taki sposób uzyskujemy spersonalizowany widok na graf. Równanie, które opisuje spacery losowe z restartami wygląda tak samo jak uogólniona wersja algorytmu PageRank:

$$Q = \alpha W + (1 - \alpha)R, \quad (2.11)$$

gdzie:

- α - współczynnik reprezentujący prawdopodobieństwo powrotu do startowego wierzchołka, liczba w zakresie (0,1)
- W - definiuje macierz przejść, gdzie $W[i, j]$ określa prawdopodobieństwo przejścia z wierzchołka i do j
- R - wektor startowy tzn. $R[i] = 1$, jeśli i jest wierzchołkiem startowym

Spacer losowy różni się PageRanku tym, że wektor startowy R posiada wartość jedną tylko dla jednej wierzchołka dla którego tworzymy ranking, pozostałe są zerami, a w PageRanku wszystkie wartości w R są jedynkami [1].

Cały proces modelowania może przebiegać na różne sposoby. W innych pracach pojawiają przykłady wykorzystania skierowanych oraz nieskierowanych grafów, wierzchołkami w grafie mogą być użytkownicy, przedmioty lub tagi [11]. Przekrój różnych aplikacji spacerów losowych z restartami pokazuje jego elastyczność oraz odporność na takie problemy jak rzadkość danych (ang. *data sparsity*, które dotyczą metody collaborative filtering wykorzystujące pamięć, a nie jakw tym przypadku model. W dodatku umożliwia połączenie takich czynników jak sieć zależności oraz preferencje użytkownika, co zostanie wykorzystane w implementacji systemu.

2.8 Absorbujące spacery losowe

Ostatnim rodzajem spacerów omówionych w tej pracy są absorbujące spacery losowe, które podobnie jak spacery losowe z restartami są wykorzystywane do personalizacji wyników. Jednakże przyjmują inną taktykę, w tym podejściu spacer odbywa się jak w normalnym spacerze losowym, lecz w grafie zostają wyróżnione stany absorbujące (ang. *absorbing states*). Wejście do takiego stanu oznacza koniec naszego spaceru, bo nie mamy z niego żadnych ścieżek wychodzących. Ten sposób powstał, aby zapewnić możliwość skupienia się na pewniej grupie wierzchołków w grafie. Jeśli w grafie wierzchołki reprezentują zarówno użytkowników, przedmioty jak i tagi, zastosowanie zwykłego spaceru z nawrotami jest kłopotliwe w złożonych systemach. Wtedy wystarczy uznać przedmioty za stany absorbujące, następnie rozpocząć symulacje losowe spacery i zliczyć wyniki, które zwrócą nam żądana listę produktów.



Implementacja systemu

3.1 Opis zadania

Praktyczną część pracy stanowi stworzenie systemu rekomendacji wykorzystującego model, czyli opisanego wcześniej podejścia model-based collaborative filtering. Taki silnik w oparciu o losowy spacer na grafie ma rozwiązać problem utworzenia listy najlepszych propozycji recenzentów dla grupy naukowców. Rekomendacje będą opierać się na połączeniach między użytkownikami, które istnieją, jeśli w przeszłości współpracowali przynajmniej przy jednej pracy naukowej.

Pierwszym krokiem implemetacji było utworzenie bazy danych. W tym celu wykorzystano gotową bazę z *dblp* oraz kadrę z Katedry Informatyki Wydziału Podstawowych Problemów Techniki, która posłużyła do prezentacji wyników. Następnym zadaniem była implementacja samego algorytmu rekomendacji. Jako pierwszą rozpatrzono wersję, która tworzy listę rankingową dla prac z jednym, a następnie z dwoma autorami. Ostatnim etapem było rozpatrzenie specyficznego przypadku rekomendacji, gdy lista dostępnych recenzentów jest specyzowana przy pomocy listy.

3.2 Technologie

Przy tworzeniu systemu wykorzystano język Julia, który został powstał w 2012 roku w celu połączenia składni oraz interaktywności języków takich jak Python, Matlab czy R, oraz szybkości kompilacji takich języków jak Fortan czy C. Do przetrzymywania i przetwarzania danych wykorzystana została biblioteka LightGraphs [12]. Projekt powstał na ostatnich stabilnych wersji oprogramowania Julia w wersji 1.0.5 (2019-09-09) oraz biblioteka LightGrahs w wersji 1.3.0.

3.3 Baza danych

Podczas implementacji algorytmów oparto się na dwóch bazach danych. Pierwszą wykorzystaną w fazie początkowej jest stworzona przez J. Leskovec z Uniwersytetu Standforda sieć współpracy między naukowcami zajmującymi się tematami z dziedziny Informatyki [7]. Cała sieć opiera się na otwartej bibliografii *dblp* zawierającej informacje o artykułach i konferencjach w informatyce. Naukowców reprezentujemy przy pomocy węzłów w nieskierowanym spójnym grafie, którzy są połączeni, jeśli razem opublikowali wspólną pracę.



Jednakże w ostatecznych testach w celu zobrazowania działania systemu na realnym przypadku posłużono się stworzoną przez autora bazą, która reprezentuje sieć współpracy między pracownikami Katedry Informatyki WPPT [15]. Podobnie jak w przykładzie z *dblp* powstały nieskierowany graf łączy krawędzią dwóch naukowców, w momencie, gdy współpracowali podczas tworzenia pracy naukowej. W opracowaniu struktury posłużono się informacjami z zbioru danych *ResearchGate* oraz *dblp*.

Po opracowaniu sieci współpracy natrafiono jednak na problem, powstały grał nie był spójnym, czego wymaga od nas zastosowanie spacerów losowych. Ta komplikacja wynikała z faktu, że niektórzy naukowcy współpracują w swoim małym gronie tworząc odrębne sieci, lub nie współpracowali z rozpatrywaną grupą osób, pojawiając się jako tzw. *czarne owce*, czyli elementy dla których nie można przeprowadzić rekomendacji. W celu wyeliminowania tych niedogodności zdecydowano się na wykorzystywanie metody hybrydowej Content-Boosted Collaborative Filtering, gdzie w sieci powiązań wykorzystujemy dodatkowe informacje o użytkownikach. Bazując na rozwiązaniu z [2] do modelu dodano dodatkowe informacje w postaci 8 tagów:

- algorytmy,
- bezpieczeństwo komputerowe,
- programowanie,
- bazy danych,
- matematyka,
- technologie sieciowe,
- systemy wbudowane,
- big data.

Zostały one następnie przypisane do konkretnych osób odpowiadającej tematyce w jakiej się specjalizuje i umieszczone w grafie tworzącym sieć powiązań. Dzięki temu już na początku, nawet dla osoby, która nie współpracowała z innymi jesteśmy w stanie zaproponować recenzentów na podstawie tego w czym się specjalizują. Te dodatkowe informacje to rodzaj profilu użytkownika, który został opisany w rozdziale 2.3.

3.4 Mechanizm działania systemu rekomendacji

Powstałe zależności zapamiętujemy przy pomocy grafu nieskierowanego, gdzie nasze tagi pełnią rolę specjalnych wierzchołków zwiększających zależność między użytkownikami.

Aby mówić o spacerze musimy jednak najpierw zdefiniować jak będziemy się po nim poruszać, pojedynczy krok na naszym grafie przebiega następująco: z pewnym prawdopodobieństwem wylosuj tag, do którego przypisany jest naukowiec lub jednego z jego sąsiadów i zwróć go.

Data: obecny wierzchołek

Result: sąsiad wierzchołka lub tag

```
1 Funkcja Pojedynczy_krok(obecny_wierzcholek):  
2   if Random() > prawdopodobienstwo then  
3     return Randomowy_tag  
4   else  
5     return Sąsiad_obecnego_wierzchołka
```

Następnie wykorzystując takie kroki możemy skonstruować spacer losowy z restartami opisanymi w 2.7. W uproszczeniu działanie takiego spaceru przebiega następująco: zaczynamy od pewnej krawędzi oznaczając ją jako obecną, a potem dla zadanej przez zmienną ilości kroków przechodzimy do jej sąsiada, lub z pewnym prawdopodobieństwem wracamy do punktu startowego i powtarzamy czynność. Na końcu (wiersz 7 – 8) upewniamy się że nie zatrzymaliśmy się w punkcie początkowym lub tagu.

Pseudokod 3.1: Spacer losowy

Data: obecny wierzchołek, który reprezentuje osobę dla której tworzymy rekomendacje, grag

Result: wierzchołek, który reprezentuje propozycje recenzenta

```
1 obecny_wierzcholek = startowy_wierzcholek  
2 for i ← 1 to liczba_kroków do  
3   if Random() > prawdopodobienstwo then  
4     obecny_wierzcholek = startowy_wierzcholek  
5   else  
6     obecny_wierzcholek = pojedynczy_krok(obecny_wierzcholek)  
7 while obecny_wierzcholek == startowy_wierzcholek or obecny_wierzcholek == tag do  
8   obecny_wierzcholek = pojedynczy_krok(obecny_wierzcholek)
```

Tak stworzony spacer zatrzymuje się w wierzchołku z częstotliwością zależną od tego ile ścieżek od punktu startowego. Ilością kroków oraz prawdopodobieństwem powrotu do początkowego wierzchołka jesteśmy w stanie sterować z jakim rozproszeniem system będzie zapewniał propozycje.

W następnej kolejności cały proces tworzenia rankingu recenzentów opiera się na symulowaniu wielu takich losowych spacerów na stworzonym grafie oraz zliczaniu wierzchołków, w których spacer zakończył się. Na tej podstawie tworzony jest ranking osób, który najlepiej pasują do danej osoby.

Drugim zadaniem było rozpatrzenie przypadku, gdy chcemy znaleźć recenzenta dla pracy napisanej przez dwóch autorów. Pierwszym krokiem jest posłużenie się algorytmem z pierwszego do wyznaczenia dwóch listy rankingowych dla obu nakowców osobno, a następnie wybranie interesującej nas części wspólnej. Musimy jednak uwzględnić, że jeśli jeden z recenzentów uzyskałby wysoki wynik u jednego naukowca, ale niski u drugiego albo wcale, jego średni wynik i tak zapewniałby mu wysoką propozycję w rankingu, mimo słabego dopasowania. W związku z nie można było skorzystać ze średniej arytmetycznej bez wcześniejszej normalizacji



ocen. Problem rozwiązano stosując średnią harmoniczną, która świetnie sprawdza się, gdy potrzebna jest średnia z ocen [4]. Obliczamy ją w następujący sposób:

$$\frac{n}{\frac{1}{a_1} + \frac{1}{a_2} + \dots + \frac{1}{a_n}} \quad (3.1)$$

Jeśli jeden z recenzentów uzyska wysoki wynik u jednego np. 50 i niski u drugiego np. 4. Jego wynik od teraz będzie wynosił $\frac{2}{\frac{1}{50} + \frac{1}{4}} = 7.407$, a nie jak dla średniej arytmetycznej 27. W ten sposób nasza średnia jest bardziej skierowana ku wartości mniejszej. Analogicznie do tego rozwiązania można w prosty sposób rozszerzyć na większą liczbę autorów, wykorzystując ogólny 3.1 do obliczenia średniej dla kolejnych osób.

Ostatnim etapem implementacji było opracowanie metody na stworzenie rankingu, gdy zbiór naszych recenzentów jest określony przez listę. W tym celu posłużono się ostatnim rodzajem spacerów omówianych w pracy, a mianowicie absorbującymi spacerami losowymi 2.8. Mechanizm działania przypomina globalne systemy rankingowe, z tym określamy stany absorbujące, z których nie możemy już wyjść. Nasz „losowy surfer” krąży po grafie zaczynając od osoby, dla której tworzymy rekomendacje aż do momentu, gdy wpadnie do stanu absorbującego, czyli w tym przypadku natrafi na wierzchołek reprezentujący jednego z recenzentów.

Pseudokod 3.2: Absorbujący spacer

Data: naukowiec, dla którego tworzymy ranking oraz lista recenzentów

Result: recenzent z listy

```

1 obecny wierzchołek = naukowiec
2 while true do
3   current edge = wylosuj z jednego z sąsiadów obecnego wierzchołka
4   if obecny wierzchołek ← 1 to lista recenzentów then
5     break
6 return obecny wierzchołek
```

Podobnie jak w spacerach z restartami powyższy algorytm odpalany jest wielokrotnie w celu symulacji wielu takich spacerów, a wyniki są sumowane. To rozwiązanie posiada wiele zalet, między innymi możliwe jest wybranie takich recenzentów, którzy są w danym momencie dostępni lub możliwe jest opracowanie listy tych, którzy specjalizują się w danej dziedzinie, lub wyeliminowanie tych, którzy napisali wspólnie wiele prac, więc zajmują się z dużym prawdopodobieństwem tym samym zagadnieniem, lecz są połączeni w negatywny z naszego punktu widzenia sposób np. są spokrewnieni.

W pracy podjęto również próbę stworzenia modelu, który jest opisany przy pomocy grafu ważnego, gdzie wagę z wierzchołka u do wierzchołka v definiujemy jako:

$$waga(u,v) = \frac{\text{ilość wspólnych prac } u \text{ z } v}{\text{suma wszystkich prac napisanych przez } u}$$

W takim przypadku szansa na krok do sąsiedniego wierzchołka nie jest jednolita, lecz zależy od powyższej wagi. Jednakże takie podejście stworzył ogromny problem braku różnorodności propozycji, czyli częsty problem tzw. długiego ogona. Osoby, które są ścisłymi współpracownikami lub mają wiele prac pojawiają się w czołówce ranking u każdej osoby. Z tego powodu zrezygnowano z dalszych prób wykorzystania takich informacji.

Testy algorytmów

4.1 Przykład użycia

Celem zobrazowania działania dwóch pierwszych algorytmów zostaną zaprezentowane wyniki wywołań dla dwóch wybranych naukowców z Katedry Informatyki. Program uruchomiono trzykrotnie w celu wyjaśnienia własności silnika rekomendacji. Wyniki przedstawiono w tabeli 4.1 oraz 4.2.

Miejsce	Proponowany recenzent	Specjalizacje	Wynik
Iteracja I			
1	dr inż. Małgorzata Sulkowska	algorytmy, bigdata, programowanie	100.0
2	prof. dr hab. Jacek Cichoń	matematyka, bigdata	95.0
3	prof. dr hab. Mirosław Kutylowski	bezpieczeństwo, sieci komputerowe	86.0
4	dr inż. Zbigniew Gołębiowski	algorytmy, bazy	73.0
5	dr inż. Przemysław Błaśkiewicz	wbudowane, bezpieczeństwo	69.0
Iteracja II			
1	dr inż. Małgorzata Sulkowska	algorytmy, bigdata, programowanie	90.0
2	prof. dr hab. Mirosław Kutylowski	bezpieczeństwo, sieci komputerowe	88.0
3	dr inż. Przemysław Błaśkiewicz	wbudowane, bezpieczeństwo	77.0
4	prof. dr hab. Jacek Cichoń	matematyka, bigdata	71.0
5	dr inż. Marcin Zawada	programowanie, sieci komputerowe	70.0
Iteracja III			
1	prof. dr hab. Jacek Cichoń	matematyka, bigdata	97.0
2	dr inż. Małgorzata Sulkowska	algorytmy, bigdata, programowanie	86.0
3	dr inż. Marcin Zawada	programowanie, sieci komputerowe	84.0
4	prof. dr hab. Mirosław Kutylowski	bezpieczeństwo, sieci komputerowe	71.0
5	dr inż. Przemysław Błaśkiewicz	wbudowane, bezpieczeństwo	69.0

Tablica 4.1: Przykład użycia algorytmu numer 1 dla prac z jednym autorem dla dr inż. Jakuba Lemiesza dla którego w ramach modelu zostały przypisane specjalizacje: algorytmy, programowanie i bigdata.

Zgodnie ze zdrowym rozsądkiem, w pierwszej kolejności prezentowane są najlepsze wyniki (ang. *Top-N recommendation*). Należy zauważyć, że w każdej iteracji zwracane są inne wyniki, lecz proponowane osoby różnią się tylko kolejnością. Osoba, która zajmuje pierwsze miejsce w kolejnym wywołaniu programu nie znajdzie się z tyłu stawki. Na podstawie kilku najwyższych notowanych pozycji można wytyczyć grupę osób, które osiągają podobnie wysokie wyniki.



Miejsce	Proponowany recenzent	Specjalizacje	Wynik
Iteracja I			
1	prof. dr hab. Mirosław Kutylowski	bezpieczeństwo, sieci komputerowe	70.0
2	dr hab. inż. Marek Klonowski	algorytmy, sieci	67.0
3	dr inż. Przemysław Błaśkiewicz	wbudowane, bezpieczeństwo	59.0
4	dr inż. Jakub Lemiesz	algorytmy, programowanie, bigdata	57.0
5	dr inż. Łukasz Krzywiecki	sieci komputerowe, bezpieczeństwo	54.0
Iteracja II			
1	dr hab. inż. Marek Klonowski	algorytmy, sieci	67.0
2	dr inż. Jakub Lemiesz	algorytmy, programowanie, bigdata	66.0
3	prof. dr hab. Mirosław Kutylowski	bezpieczeństwo, sieci komputerowe	60.0
4	dr hab. Paweł Zieliński	algorytmy, bazy, bigdata	54.0
5	dr inż. Przemysław Błaśkiewicz	wbudowane, bezpieczeństwo	54.0
Iteracja III			
1	dr inż. Jakub Lemiesz	algorytmy, programowanie, bigdata	67.0
2	dr inż. Przemysław Błaśkiewicz	wbudowane, bezpieczeństwo	65.0
3	dr hab. inż. Marek Klonowski	algorytmy, sieci	64.0
4	prof. dr hab. Mirosław Kutylowski	bezpieczeństwo, sieci komputerowe	63.0
5	dr inż. Łukasz Krzywiecki	sieci komputerowe, bezpieczeństwo	52.0

Tablica 4.2: Przykład użycia algorytmu numer 1 dla prac z jednym autorem dla prof. dr hab. Jacka Cichonia, dla którego dla potrzeb modelu zostały przypisane specjalizacje: algorytmy, matematyka oraz bigdata.

Warto spostrzec, że przypisane specjalizacje rekomendowanych osób, w dużej mierze pokrywają się z dziedzinami wybranej osoby. Dla dr inż. Jakuba Lemiesz, któremu przypisano algorytmy, programowanie i bigdata, pierwsze i drugie miejsce w zestawieniu zajmuje dr inż. Małgorzata Sulkowska, której przypisano takie same dziedziny informatyki. Trochę inaczej sprawa wygląda dla prof. dr hab. Jacka Cichonia, któremu prezentowane są głównie osoby, które podobnie jak on posiada najwięcej połączeń w grafie. Dzieje się tak, ponieważ profesor pojawia się w pracach z większością Katedry Informatyki WPPT.

Następnie dla tych samych osób uruchomiono drugi algorytm, który ma za zadanie wyznaczyć wspólne propozycje ze zbioru wyników uzyskanych przy pomocy pierwszego. Zgodnie z założeniem najwyżej punktowane są osoby, które osiągnęły wysokie wyniki u obu osób. Wyniki znajdują się tabelki 4.3.

4.2 Lista recenzentów

Jednakże najciekawsze narzędzie zapewnia stworzony algorytm wykorzystujący absorbujące spacery losowe. Umożliwia on stworzenie rankingu dla wybranych przez nas osób. Jest to bardzo użyteczne, w momencie, gdy na przykład dostępnych jest tylko kilku naukowców i chcemy dla nich ustalić zestawienie.

Rozważmy, że mamy do dyspozycji listę losowo wybranych recenzentów i chcemy wśród

Miejsce	Proponowany recenzent	Specjalizacje	Wynik
Iteracja I			
1	prof. dr hab. Mirosław Kutylowski	bezpieczeństwo, sieci komputerowe	73.22
2	dr hab. inż. Marek Klonowski	algorytmy, sieci	65.86
3	dr inż. Przemysław Błaśkiewicz	wbudowane, bezpieczeństwo	64.61
4	dr inż. Marcin Zawada	programowanie, sieci komputerowe	58.16
5	dr inż. Małgorzata Sulkowska	algorytmy, bigdata, programowanie	55.68
Iteracja I			
1	dr inż. Małgorzata Sulkowska	algorytmy, bigdata, programowanie	65.09
2	dr inż. Marcin Zawada	programowanie, sieci komputerowe	62.98
3	prof. dr hab. Mirosław Kutylowski	bezpieczeństwo, sieci komputerowe	62.40
4	dr inż. Przemysław Błaśkiewicz	wbudowane, bezpieczeństwo	56.73
5	dr inż. Zbigniew Gołębiewski	algorytmy, bazy	53.51
Iteracja I			
1	dr inż. Zbigniew Gołębiewski	algorytmy, bazy	69.06
2	prof. dr hab. Mirosław Kutylowski	bezpieczeństwo, sieci komputerowe	65.88
3	dr inż. Przemysław Błaśkiewicz	wbudowane, bezpieczeństwo	62.79
4	dr inż. Marcin Zawada	programowanie, sieci komputerowe	61.85
5	dr hab. inż. Marek Klonowski	algorytmy, sieci	58.28

Tablica 4.3: Przykład użycia algorytmu numer 2 dla prac z dwoma autorami dla prof. dr hab. Jacka Cichonia i dr inż. Jakuba Lemiesza.

nich dla ustalić dla naukowca, kto będzie najlepiej nadawał się do recenzji. Podobnie w momencie, gdy znamy temat pracy możemy wybrać listę osób specjalizujących się w tej dziedzinie i wybrać tę, która również będzie najlepsza.

Miejsce	Proponowany recenzent	Wynik
1	prof. dr hab. Mirosław Kutylowski	255
1	dr inż. Przemysław Błaśkiewicz	236
3	dr inż. Łukasz Krzywiecki	189
4	dr Filip Zagórski	170
5	dr Przemysław Kubiak	66
6	dr inż. Anna Lauks-Dutka	45
7	dr inż. Wojciech Wodo	39

Tablica 4.4: Przykład użycia algorytmu numer 3 dla dr Marcin Michalski na liście osób specjalizujących się w bezpieczeństwie komputerowym.

Rozkład takich osób prezentuje się w tabeli 4.4, wynik zależy od ilości stworzonych prac połączeń z innymi osobami z sieci współpracy, w TOP-4 znajdują się osoby, które stworzyły najwięcej materiałów z różnymi osobami, więc ich wynik jest największy.



4.3 Współczynnik tłumienia

Ten test został przeprowadzono w celu ustalenia rozproszenia rekomendacji w zależności od współczynnika tłumienia α oraz sprawdzenia poprawności działania algorytmów. Algorytmy odpalono 100-krotnie dla każdego z 28 naukowców z Katedry Informatyki, a następnie obliczono ile różnych propozycji pojawia się w TOP-5 średnio dla różnych wartości α .

α	Średnia ilość różnych propozycji dla TOP-5 rekomendacji	
	Wersja z jednym autorem pracy	Wersja z dwoma autorami
0.05	8.939	9.606
0.15	8.953	11.147
0.25	8.957	12.451
0.35	9.000	12.915
0.45	9.025	12.984
0.55	9.057	12.746
0.65	9.046	11.973
0.75	9.025	10.855
0.85	9.550	9.702
0.95	10.985	9.610

Tablica 4.5: W tym teście sprawdzono ile różnych wyników pojawia się w TOP-5 rankingu zależnie od zastosowanego współczynnika tłumienia.

Zgodnie z naszą intuicją, wraz ze wzrostem prawdopodobieństwa na powrót do wierzchołka startowego (czyli w przypadku, gdy współczynnik maleje, bo prawdopodobieństwa na powrót jest równe $1 - \alpha$) rozporoszenie wyników maleje. Zastosowanie współczynnika równego 0.85, sugerowanego przez [11] niemal okrywa się z uzyskanymi wynikami, które sugerują, że 0.75 zapewnia podobne skupienie jak równy 0.25. Zmniejszając parametr z 0.95 na 0.75–0.85 średnio zyskujemy, nawet dwie odrębne propozycje mniej, co czyni wyniki bardziej powtarzalnymi.

Z kolei w przypadku algorytmu natrafiamy na ciekawe zjawisko, że najbardziej potwarzające się wyniki trafiają się przy dużym oraz bardzo małym współczynniku, wynika to najprawdopodobniej z małej próbki danych jaką stanowi grupa 28 naukowców. Przy małym współczynniku spacer zamienia się niemal w zwykły spacer bez powrotów (teleportacji) i najprawdopodobniej wszystkim proponuje te same osoby, które posiadają najwięcej połączeń z innymi.

Instalacja i wdrożenie



Podsumowanie

W niniejszej pracy udało się opisać główne metody wykorzystywane w silnikach rekomendacji, collaborative filtering oraz content based, a następnie wskazać różnice w ich stosowaniu. Ustalono zasady zbierania informacji o użytkowniku, formę ich przechowywania oraz porównywania wyników. Objąsniiono również najważniejsze miary stosowane do porównywania recenzowanych obiektów. Kolejno skupiono się na dość niezbadanym podejściu zastosowania procesów jakim są spacery losowe w celu filtracji informacji w takich systemach. Omówiono, gdzie wykorzystuje się takie spacery, jak działają oraz jakie jest ich podział ze względu na użycie w systemach rekomendacji.

W dalszej kolejności omówiono główne problemy jakie można napotkać podczas tworzenia takich silników. Zimny start oraz rzadkość danych, które pojawiają, gdy nie mamy lub mamy zbyt mało danych o użytkowniku można zlikwidować wykorzystując metody hybrydowe, na przykład użyciem ankietyzacji na nowo utworzonym koncie w collaborative filtering lub umieszczeniem dodatkowym informacji w sieci kolaboracji w postaci tagów lub innych etykiet.

Na koniec opisano proces tworzenia takiego systemu opartego o błędzenie losowe, w celu rozwiązania problemu doboru recenzenta dla grupy naukowców. Zaproponowano w tym celu 3 algorytmy, które pozwalają na stworzenie rankingu oceniającego dopasowanie recenzenta do zadania. W stworzonym modelu wykorzystano tagi, które są przykładem prostych profili użytkowników, które reprezentują wybrane przez nas cechy pracy naukowca. Początkowo stworzono system rekomendacji dla jednej osoby, następnie przedstawiono sposób na rozwinięcie rekomendacji dla dwóch osób jednocześnie. W ostatni algorytmie ukazano sposób rekomendacji dla zadanej listy recenzentów, zastosowano w tym celu absorbujące spacery losowe.

W dalszym rozwoju systemu można byłoby rozszerzyć system rankingowy dla jeden lub dwóch osób, na wiele autorów. W tym celu należałoby sprawdzić czy zastowanie średniej harmoniczej również sprawdziłoby się podczas uśredniania wyników, czy konieczne byłoby inny rodzaj normalizacji wyników.



Bibliografia

- [1] C. Bhatia. Random walk with restart and its applications. 2019.
- [2] T. Bogers. Movie recommendation using random walks over the contextual graph. 2010.
- [3] L. Chen, G. Chen, F. Wang. Recommender systems based on user reviews: The state of the art. 2015.
- [4] Corporate Finance Institute. Harmonic mean, 2019. [Online; accessed December, 2019].
- [5] Facebook Investor Result. Facebook reports third quarter 2019 results, 2019. [Online; accessed December, 2019].
- [6] P. Gupta, A. Goel, J. Lin, A. Sharma, D. Wang, R. Zadeh. Wtf: The who to follow service at twitter. 2013.
- [7] J. Leskovec. Snap: Network datasets: Dblp collaboration network. Web page: <https://snap.stanford.edu/data/com-DBLP.html>.
- [8] G. Linden, B. Smith, J. York. Amazon.com recommendations item-to-item collaborative filtering. 2015.
- [9] M. Mitzenmacher, E. Upfal. *Metody probabilistyczne i obliczenia*. Wydawnictwa Naukowo-Techniczne, 2009.
- [10] T. Morzy, M. Morzy, A. Leśniewska. Eksploracja tekstu.
- [11] L. Semage. Recommender systems with random walks: A survey. 2017.
- [12] J. F. Seth Bromberger, other contributors. Juliagraphs/lightgraphs.jl: an optimized graphs package for the julia programming language, 2017.
- [13] H. Shimodaira. Similarity and recommender systems. 2015.
- [14] Wikipedia, the free encyclopedia. Long tail, 2019. [Online; accessed December, 2019].
- [15] WPPT. Katedra informatyki wppt - kadra, 2019. [Online; accessed December, 2019].



Zawartość płyty CD

W tym rozdziale należy krótko omówić zawartość dołączonej płyty CD oraz opis uruchamiania.

